UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE

ENGENHARIA DE SOFTWARE

RELATÓRIO TÉCNICO

Engenharia de Dados – Schema 1: Dados Públicos

Projeto AF Sacolas

Responsável: Letícia Rayane Pereira da Silva

Natal – RN

2026

Sumário

1 Introdução **2**

2 Objetivo **2**

3 Fonte dos Dados **2**

4 Estruturação do Banco de Dados **3**

5 Importação dos Arquivos CSV **4**

6 Consultas SQL e Análise dos Resultados **4**

6.1 Identificação do período dos dados 5

6.2 Análise geral dos valores dos produtos 5

6.3 Análise das formas de pagamento 6

6.4 Evolução mensal das vendas 7

6.5 Análise da situação dos pedidos 8

6.6 Análise dos pedidos por estado brasileiro 9

6.7 Análise do valor médio dos pedidos por estado 10

7 Principais Indicadores Identificados **11**

8 Relação dos Resultados com o Projeto AF Sacolas **12**

9 Considerações sobre a Análise **12**

10 Conclusão **13**

11 Referência **13**

1. Introdução

Este relatório apresenta as atividades desenvolvidas na função de Engenharia de Dados, especificamente na construção do Schema 1 – Dados Públicos, do projeto AF Sacolas.

O objetivo desta etapa é utilizar dados públicos relacionados ao comércio eletrônico brasileiro para identificar indicadores que ajudem a contextualizar a importância do mercado de vendas pela internet e sua relação com oportunidades comerciais para empresas que trabalham com embalagens, sacolas personalizadas e materiais promocionais.

Para isso, foi utilizado um conjunto de dados público contendo informações sobre pedidos, produtos, pagamentos e clientes de uma plataforma de comércio eletrônico brasileira. Os arquivos foram organizados e importados para um banco de dados MySQL, permitindo a realização de consultas analíticas por meio de funções de agregação e agrupamento.

2. Objetivo

O principal objetivo desta etapa é estruturar e analisar dados públicos de comércio eletrônico, utilizando consultas SQL para gerar indicadores que contribuam para a justificativa de mercado do sistema AF Sacolas.

Entre os objetivos específicos, destacam-se:

- Selecionar uma base de dados pública relacionada ao comércio eletrônico;
- Importar os arquivos CSV para um banco de dados MySQL;
- Organizar as informações em tabelas estruturadas;
- Desenvolver consultas SQL utilizando funções como `SUM`, `AVG`, `MAX`, `MIN` e `COUNT`;
- Agrupar os dados por período, forma de pagamento e localização geográfica;
- Identificar tendências e indicadores que possam contribuir para a contextualização do mercado.

3. Fonte dos Dados

Foi utilizado o conjunto de dados *Brazilian E-Commerce Public Dataset by Olist*, disponibilizado na plataforma Kaggle.

A base contém registros históricos de operações de comércio eletrônico realizadas no Brasil, incluindo informações sobre pedidos, itens vendidos, pagamentos, clientes, vendedores e produtos.

O conjunto de dados abrange registros de setembro de 2016 a outubro de 2018, possibilitando a análise de diferentes indicadores relacionados às vendas pela internet.

Foram selecionados inicialmente quatro arquivos CSV:

- `olist_orders_dataset.csv`: informações sobre os pedidos, situação e datas das compras;
- `olist_order_items_dataset.csv`: informações sobre os itens vendidos, preços e valores de frete;
- `olist_order_payments_dataset.csv`: informações sobre as formas e os valores de pagamento;
- `olist_customers_dataset.csv`: informações sobre os clientes e suas respectivas localizações.

A escolha dessa base ocorreu por sua relação direta com o comércio eletrônico, permitindo observar o volume de pedidos, a movimentação financeira e a distribuição geográfica dos consumidores.

Observação: os dados não representam especificamente o comércio de sacolas ou embalagens. Eles são utilizados como indicadores indiretos da atividade do comércio eletrônico brasileiro e como contexto para discutir oportunidades relacionadas ao mercado atendido pelo AF Sacolas.

4. Estruturação do Banco de Dados

Para armazenar e analisar as informações, foi criado um banco de dados no MySQL com o nome:

`schema1_dados_publicos`

Dentro desse banco, foram criadas quatro tabelas principais:

Tabela 1: Estrutura das tabelas do banco de dados

Tabela	Descrição
`orders`	Armazena os dados dos pedidos e suas datas.
`order_items`	Armazena os itens vendidos, seus preços e fretes.
`order_payments`	Armazena os pagamentos e suas modalidades.
`customers`	Armazena os dados dos clientes e sua localização.

As tabelas foram estruturadas considerando os campos presentes nos arquivos originais. Também foram definidos tipos de dados adequados para cada informação, como campos de texto, datas e valores numéricos decimais.

As relações entre as tabelas permitem associar os pedidos aos seus respectivos itens, pagamentos e clientes, possibilitando análises integradas.

5. Importação dos Arquivos CSV

Após a criação do banco de dados e das tabelas, foi realizada a importação dos arquivos CSV utilizando o comando `LOAD DATA LOCAL INFILE`, disponibilizado pelo MySQL.

Esse comando permite carregar os registros diretamente dos arquivos para as tabelas correspondentes, evitando a necessidade de inserir cada registro individualmente.

Ao final da importação, foram obtidos os seguintes resultados:

Tabela 2: Quantidade de registros importados

Tabela	Registros importados
orders	99.441
order_items	112.650
order_payments	103.886
customers	99.441
Total	**415.418**

A importação foi concluída com sucesso, permitindo a utilização dos dados nas consultas analíticas.

6. Consultas SQL e Análise dos Resultados

Nesta etapa, foram desenvolvidas consultas SQL para extrair indicadores relevantes da base de dados. Foram utilizadas funções de agregação, como `SUM`, `AVG`, `MAX`, `MIN` e

`COUNT`, além de agrupamentos com `GROUP BY` e ordenação com `ORDER BY`.

6.1. Identificação do período dos dados

Inicialmente, foi realizada uma consulta para identificar a primeira e a última data de compra registrada na base.

Consulta SQL:

```sql
SELECT
    MIN(order_purchase_timestamp) AS primeira_compra,
    MAX(order_purchase_timestamp) AS ultima_compra
FROM orders;
```

Resultado:

- Primeira compra: 04/09/2016;
- Última compra: 17/10/2018.

Análise:

A consulta permitiu identificar o intervalo temporal coberto pelo conjunto de dados. Esse período serve como referência para as análises de evolução das vendas e comparação entre os meses e anos disponíveis.

6.2. Análise geral dos valores dos produtos

Foi realizada uma consulta para identificar o valor total dos produtos comercializados, o preço médio dos itens e os maiores e menores valores registrados.

Consulta SQL:

```sql
SELECT
    SUM(price) AS valor_total_produtos,
    AVG(price) AS preco_medio_produto,
    MAX(price) AS maior_preco,
    MIN(price) AS menor_preco
FROM order_items;
```

Resultado:

Tabela 3: Indicadores gerais dos valores dos produtos

Indicador	Resultado
Valor total dos produtos	R$ 13.591.643,70
Preço médio por item	R$ 120,65
Maior preço registrado	R$ 6.735,00
Menor preço registrado	R$ 0,85

Análise:

Os resultados demonstram uma movimentação expressiva de valores na comercialização de produtos pela plataforma analisada. O valor total dos itens ultrapassou R$ 13,5 milhões no período considerado.

O preço médio de aproximadamente R$ 120,65 representa a média dos valores individuais registrados na tabela de itens, e não o valor médio de cada pedido.

6.3. Análise das formas de pagamento

Para compreender as modalidades de pagamento utilizadas pelos consumidores, foi realizada uma consulta agrupando os registros por tipo de pagamento.

Consulta SQL:

```sql
SELECT
    payment_type,
    COUNT(*) AS quantidade_pagamentos,
    SUM(payment_value) AS valor_total,
    AVG(payment_value) AS valor_medio
FROM order_payments
GROUP BY payment_type
ORDER BY valor_total DESC;
```

Resultado:

Tabela 4: Distribuição dos pagamentos por modalidade

Forma de pagamento	Quantidade	Valor total
Cartão de crédito	76.795	R$ 12.542.084,19
Boleto	19.784	R$ 2.869.361,27
Voucher	5.775	R$ 379.436,87
Cartão de débito	1.529	R$ 217.989,79
Não definido	3	R$ 0,00

Análise:

O cartão de crédito apresentou a maior participação financeira entre as modalidades analisadas, seguido pelo boleto bancário.

Esse resultado demonstra a relevância dos meios de pagamento digitais e tradicionais no funcionamento do comércio eletrônico, além de evidenciar a diversidade de modalidades utilizadas pelos consumidores.

6.4. Evolução mensal das vendas

Foi realizada uma análise mensal para observar a quantidade de pedidos e o valor total dos produtos comercializados ao longo do período.

Consulta SQL:

```sql
SELECT
    DATE_FORMAT(o.order_purchase_timestamp, '%Y-%m') AS mes,
    COUNT(DISTINCT o.order_id) AS quantidade_pedidos,
    SUM(i.price) AS valor_total_vendas,
    AVG(i.price) AS preco_medio_item
FROM orders o
INNER JOIN order_items i
    ON o.order_id = i.order_id
GROUP BY DATE_FORMAT(o.order_purchase_timestamp, '%Y-%m')
ORDER BY mes;
```

Principais resultados identificados:

Tabela 5: Meses com maior valor total de produtos

Mês	Pedidos	Valor total
Novembro/2017	7.451	R$ 1.010.271,37
Abril/2018	6.934	R$ 996.647,75
Maio/2018	6.853	R$ 996.517,68
Março/2018	7.188	R$ 983.213,44
Janeiro/2018	7.220	R$ 950.030,36

Análise:

A análise mensal evidencia uma movimentação significativa do comércio eletrônico, especialmente a partir de 2017. Entre os meses analisados, novembro de 2017 apresentou o maior valor total de produtos comercializados, ultrapassando R$ 1 milhão.

Os resultados permitem observar períodos de maior movimentação comercial, informação que pode contribuir para o planejamento de produção, estoque e estratégias de atendimento de empresas fornecedoras de produtos e materiais utilizados no comércio.

É importante considerar que os meses iniciais de 2016 e o último mês de 2018 possuem registros parciais, portanto não devem ser comparados diretamente com meses completos.

6.5. Análise da situação dos pedidos

Também foi realizada uma consulta para identificar a distribuição dos pedidos de acordo com sua situação.

Consulta SQL:

```sql
SELECT
    order_status,
    COUNT(*) AS quantidade,
    ROUND(
        COUNT(*) * 100.0 / (SELECT COUNT(*) FROM orders),
        2
    ) AS percentual
FROM orders
GROUP BY order_status
ORDER BY quantidade DESC;
```

Resultado:

Tabela 6: Distribuição dos pedidos por situação

Situação	Quantidade	Percentual
Entregue	96.478	97,02%
Enviado	1.107	1,11%
Cancelado	625	0,63%
Indisponível	609	0,61%
Faturado	314	0,32%
Em processamento	301	0,30%
Criado	5	0,01%
Aprovado	2	0,00%

Análise:

A maior parte dos pedidos registrados encontra-se na situação de entregue, representando aproximadamente 97% do total.

Esse resultado demonstra que a base possui predominância de pedidos concluídos, o que contribui para a análise da movimentação comercial efetivamente realizada.

6.6. Análise dos pedidos por estado brasileiro

Para identificar a distribuição geográfica dos consumidores, foi realizada uma consulta relacionando as tabelas de pedidos, itens e clientes.

Consulta SQL:

```sql
SELECT
    c.customer_state AS estado,
    COUNT(DISTINCT o.order_id) AS quantidade_pedidos,
    SUM(i.price) AS valor_total_vendas,
    AVG(i.price) AS preco_medio_item
FROM orders o
INNER JOIN customers c
    ON o.customer_id = c.customer_id
INNER JOIN order_items i
    ON o.order_id = i.order_id
GROUP BY c.customer_state
ORDER BY quantidade_pedidos DESC;
```

Principais resultados:

Tabela 7: Estados com maior quantidade de pedidos

Estado	Pedidos	Valor total
SP	41.375	R$ 5.202.955,05
RJ	12.762	R$ 1.824.092,67
MG	11.544	R$ 1.585.308,03
RS	5.432	R$ 750.304,02
PR	4.998	R$ 683.083,76
SC	3.612	R$ 520.553,34
BA	3.358	R$ 511.349,99

Análise:

O estado de São Paulo apresentou a maior quantidade de pedidos e o maior valor total de produtos comercializados. Rio de Janeiro e Minas Gerais também apresentaram participação expressiva.

Os três estados com maior quantidade de pedidos concentram aproximadamente 66% dos registros.

Essa distribuição demonstra que a atividade do comércio eletrônico possui alcance em diferentes regiões do país, embora exista uma concentração expressiva de pedidos nos estados do Sudeste.

Ressalta-se que a localização utilizada nessa consulta corresponde ao endereço cadastrado dos clientes, e não necessariamente à localização dos vendedores.

6.7. Análise do valor médio dos pedidos por estado

Além da quantidade de pedidos, foi calculado o valor médio dos produtos por pedido em cada estado, permitindo observar diferenças no valor comercializado por transação.

Consulta SQL:

```sql
SELECT
    c.customer_state AS estado,
    COUNT(DISTINCT o.order_id) AS quantidade_pedidos,
    ROUND(
        SUM(i.price) / COUNT(DISTINCT o.order_id),
        2
    ) AS valor_medio_por_pedido
FROM orders o
INNER JOIN customers c
    ON o.customer_id = c.customer_id
INNER JOIN order_items i
    ON o.order_id = i.order_id
GROUP BY c.customer_state
ORDER BY valor_medio_por_pedido DESC;
```

Dez maiores valores médios identificados:

Tabela 8: Estados com maiores valores médios por pedido

Estado	Pedidos	Valor médio
PB	532	R$ 216,67
AP	68	R$ 198,15
AC	81	R$ 197,32
AL	411	R$ 195,41
RO	247	R$ 186,80
PA	970	R$ 184,48
TO	279	R$ 177,86
PI	493	R$ 176,30
MT	903	R$ 173,26
RN	482	R$ 172,27

Análise:

Os resultados demonstram diferenças no valor médio de produtos comercializados por pedido entre os estados brasileiros.

A Paraíba apresentou o maior valor médio, seguida por Amapá e Acre. O Rio Grande do Norte também aparece entre os dez estados com maiores valores médios, ocupando a décima posição, com aproximadamente R$ 172,27 por pedido.

Essa análise contribui para compreender diferenças regionais no comportamento de compra. Entretanto, os valores não devem ser interpretados como renda dos consumidores ou como demanda específica por sacolas.

7. Principais Indicadores Identificados

A partir das consultas realizadas, foram identificados os seguintes indicadores:

- **R$ 13,59 milhões:** valor total dos produtos registrados na tabela de itens;
- **R$ 120,65:** preço médio por item;
- **99.441:** quantidade de pedidos registrados;
- **112.650:** quantidade de itens registrados;
- **97,02%:** percentual de pedidos com situação entregue;
- **R$ 1,01 milhão:** maior valor mensal de produtos identificado, em novembro de 2017;

- **41.375 pedidos:** quantidade registrada para clientes do estado de São Paulo;
- **R$ 172,27:** valor médio por pedido calculado para o Rio Grande do Norte.

Esses indicadores permitem construir uma visão geral da movimentação do comércio eletrônico brasileiro no período analisado.

8. Relação dos Resultados com o Projeto AF Sacolas

O AF Sacolas está relacionado à comercialização e personalização de sacolas destinadas a empresas, eventos e ações promocionais.

Nesse contexto, os dados analisados ajudam a contextualizar a atividade do comércio eletrônico e a movimentação de produtos em diferentes regiões do Brasil.

O crescimento e a diversidade das operações comerciais podem representar oportunidades para fornecedores de materiais utilizados na apresentação, embalagem, transporte e divulgação de produtos.

Além disso, a distribuição geográfica dos pedidos demonstra a existência de consumidores em diferentes estados, reforçando a importância de soluções comerciais que possam atender a diferentes localidades.

É importante destacar que a base utilizada não apresenta dados específicos sobre a compra de sacolas personalizadas. Portanto, os resultados não comprovam diretamente a demanda por esse produto, mas oferecem indicadores gerais do cenário comercial no qual o AF Sacolas está inserido.

9. Considerações sobre a Análise

Durante o desenvolvimento, foram realizadas algumas considerações metodológicas para garantir maior consistência dos resultados.

As consultas que relacionam pedidos e itens utilizam a identificação do pedido para associar as informações. Como um pedido pode conter vários itens, foi utilizado `COUNT(DISTINCT order_id)` para evitar contar o mesmo pedido mais de uma vez.

Também é importante separar a análise dos itens da análise dos pagamentos. Um pedido pode possuir vários itens e mais de um registro de pagamento. Por isso, a soma dos valores dos itens foi calculada diretamente na tabela `order_items`, enquanto os valores pagos foram analisados separadamente na tabela `order_payments`.

Essa separação evita a duplicação de valores em consultas que poderiam multiplicar registros ao relacionar tabelas com diferentes quantidades de linhas por pedido.

Por fim, a base possui dados históricos de 2016 a 2018. Assim, os resultados descrevem o período disponibilizado pelo conjunto de dados e não devem ser apresentados como retrato atualizado do comércio eletrônico em 2026.

10. Conclusão

A etapa de Engenharia de Dados do Schema 1 foi concluída com a seleção de uma base pública de comércio eletrônico, criação do banco de dados no MySQL, estruturação das tabelas e importação de 415.418 registros.

A partir dos dados armazenados, foram desenvolvidas consultas SQL utilizando funções de agregação, agrupamento e relacionamentos entre tabelas, permitindo identificar indicadores relacionados ao volume de pedidos, valores comercializados, formas de pagamento, situação dos pedidos e distribuição geográfica dos consumidores.

Os resultados demonstram a relevância da movimentação comercial registrada na plataforma analisada e oferecem informações que ajudam a contextualizar o mercado no qual o projeto AF Sacolas está inserido.

Dessa forma, o Schema 1 cumpre sua finalidade de transformar dados públicos em informações organizadas e indicadores analíticos, contribuindo para fundamentar a justificativa de mercado do sistema.

11. Referência

OLIST. *Brazilian E-Commerce Public Dataset by Olist*. Kaggle. Base de dados pública utilizada para a realização das análises.

Disponível em: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce.

Acesso em: 03 nov. 2026.